Работа с библиотекой сайта Liconism.com : поиск, скачивание и сканирование файлов и автоматическое извлечение звукоподражаний на японском, корейском, китайском и английском языках

https://github.com/e9krivo/-LiconismScanner-2.0.git

Выполнил: Кривошеева Е.И.

Сканирование библиотеки Liconism.com

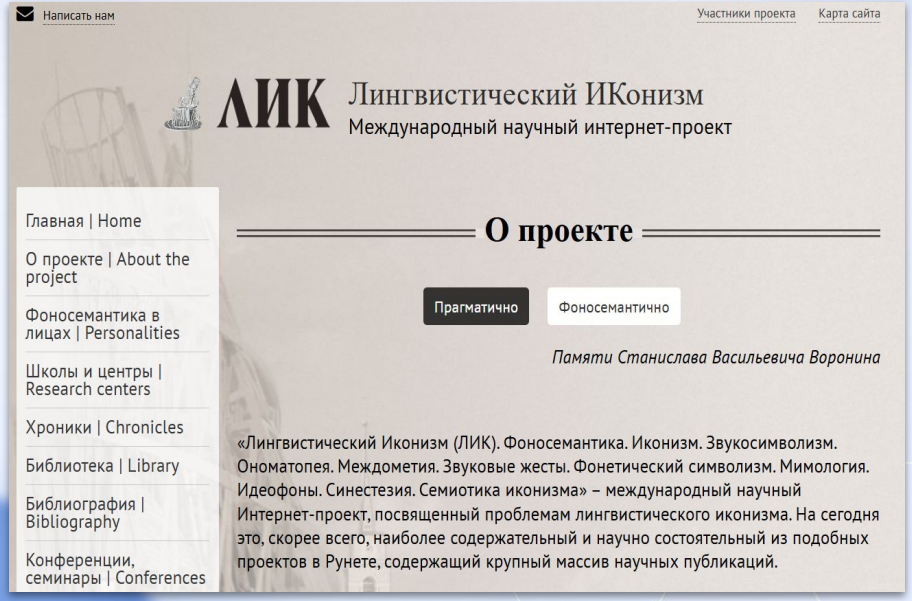

Приложение скачивает и анализирует библиотеку PDF-документов Международного научного интернет-проекта «Лингвистический Иконизм» и выполняет поиск книг, связанных с темой иконизма в восточных языках (китайский, японский, корейский).

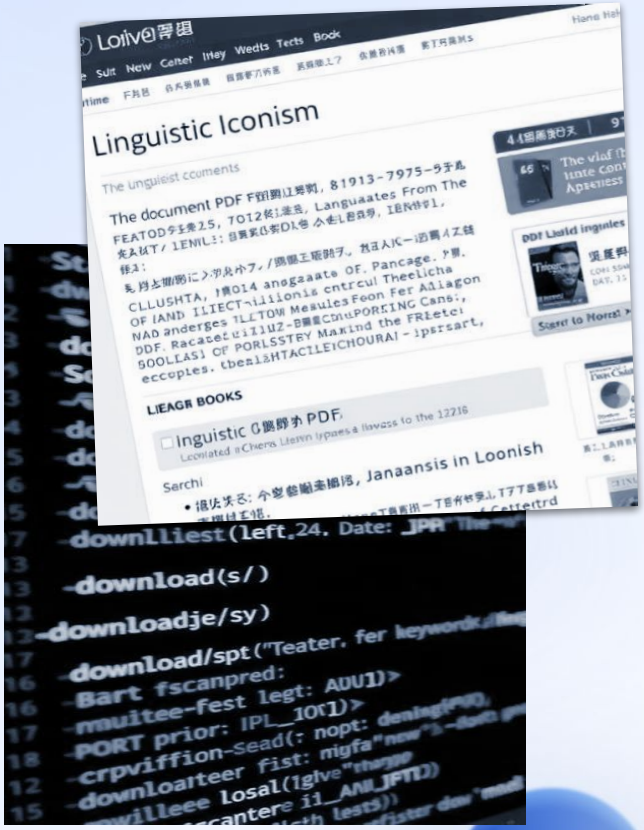

Структура проекта

downloader. py - скачивает все книги библиотеки в папку downloads/

scanner.py - сканирует PDF и ранжирует книги по релевантности

keywords.json - список ключевых слов с весами

downloads/ - создаётся автоматически при запуске downloader.py

Скачанные книги сохраняются в формате, удобном для дальнейшего анализа и обработки

Метод TF-IDF

Метод TF-IDF используется для определения релевантности книг по ключевым словам.

TF (Term Frequency) — как часто термин встречается в конкретной книге.

IDF (Inverse Document Frequency) — насколько термин редок по всей коллекции.

Комбинация TF и IDF позволяет оценить, насколько книга соответствует запросу, учитывая не только частоту ключевых слов, но и их значимость в общем контексте коллекции. Это помогает улучшить качество поиска и рекомендаций книг.

Нормирование скоров документов

Скоры всех документов нормируются в диапазон [0, 1], где 1. 0 — самая релевантная книга в коллекции.

Значения ниже 0,5 указывают на низкую релевантность документа, рекомендуется их исключить из выборки. Для более точного анализа можно использовать дополнительные параметры ранжирования.

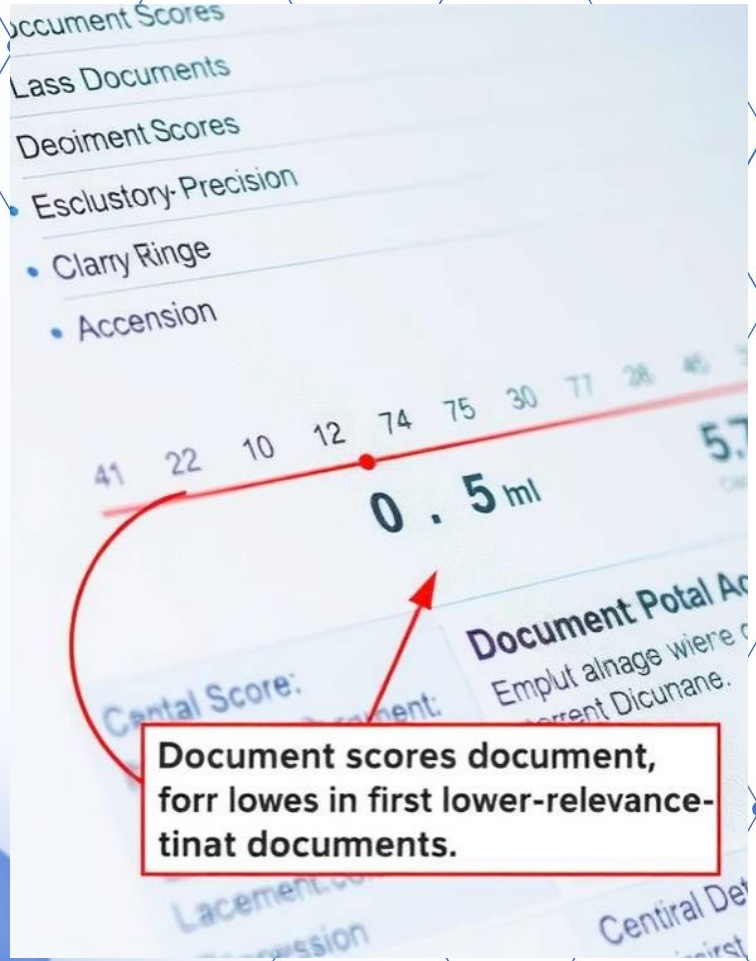

Список ключевых слов

Список ключевых слов задается в файле keywords.json

Ключевые слова трактуются как префиксы: «ономатоп» найдёт «ономатопея», «ономатопоэтический» и любые другие формы.

Файл keywords. json позволяет гибко настраивать поиск, что упрощает работу с большими объемами данных. Можно легко добавлять или удалять ключевые слова по мере необходимости.

Формат файла keywords.json

```json
{
  "ключевое_слово": вес,
  "keyword": weight
}
```

Большее значение веса указывает на более значимый вклад ключевого слова в общий анализ текста.

Веса автоматически рассчитываются алгоритмом на основе частоты и уникальности ключевых слов в корпусе документов.

Установка и запуск

Используемые пакеты

Пакет	Назначение
requests	скачивание страниц сайта и файлов PDF
beautifulsoup4	парсинг HTML, поиск ссылок на книги
urllib3	утилиты для работы с URL
pymupdf	извлечение текста из PDF
scikit-learn	TF-IDF векторизация (TfidfVectorizer)
numpy	работа с числовыми массивами и матрицами
tqdm	отображение прогресса долгих операций

Скачивание библиотеки (~600 книг, занимает продолжительное время): python downloader. py
Сканирование и ранжирование: python scanner.py
Конфигурация scanner.py
После скачивания библиотека готова к использованию.

Конфигурация scanner.py

Все параметры находятся в начале файла scanner.

py: pdf_folder, keywords_file, cutoff, top_n.

Эти параметры можно легко изменить для настройки работы скрипта под конкретные задачи. Рекомендуется внимательно ознакомиться с их значениями перед началом работы.

Вывод программы

Программа выводит статистику совпадений — для каждого ключевого слова показывает, какие конкретные термины из TF-IDF словаря были найдены и сколько их.

Помогает отлаживать keywords. json. Список книг — отсортированный по убыванию релевантности, с визуальным индикатором и численным скором.

Позволяет быстро находить наиболее релевантные источники для дальнейшего анализа.

Дообучение синтаксического парсинга для задачи построения синтаксического дерева частей речи в предложении и определения их морфологиик слайда

1. Настройка программного модуля для лингвистического анализа на базе библиотеки spaCy, который обрабатывает текст в едином цикле и на выходе выдает структуру синтаксических связей и морфологический разбор;

2. Проведено дообучение модели на подготовленных данных, что позволило добиться лучшего установления иерархических связей между компонентами предложения

Спасибо за внимание!